Medidas Descriptivas en R

Carlos Lesmes

2026-02-01

Tabla de contenidos

1 Primeros pasos ... 3
2 Medidas de tendencia central ... 4
2.1 Media aritmética ponderada ... 4
2.2 Media aritmética ... 5
2.3 Mediana ... 5
2.4 Moda ... 5
2.5 Media geométrica ... 6
2.6 Media armónica ... 6
2.7 Media general de orden h ... 7
2.8 Propiedad ... 7
3 Percentiles ... 7
3.1 Recorrido Intercuartílico ... 8
3.2 Diagrama de Caja, box and whiskers, boxplot ... 8
3.3 Cuartiles ... 10
3.4 Deciles ... 10
3.4.1 Propiedad ... 10
3.5 Recorrido intercuartílico ... 10
3.6 Bigotes ... 11
4 Medidas de dispersión ... 11
4.1 Rango ... 11
4.2 Recorrido intercuartílico ... 11
4.3 Varianza muestral ... 11
4.4 Desviación estándar muestral ... 12
4.5 Varianza poblacional ... 12
4.6 Desviación estándar poblacional ... 12
4.7 Suma de cuadrados ... 13
4.8 Desviación media ... 13
4.9 Coeficiente de variación muestral ... 13
4.10 Puntaje estandarizado o normalización ... 13
5 Medidas de forma ... 14
5.1 Momentos ... 14
5.1.1 Casos especiales ... 14

5.2 Coeficiente de sesgo o asimetría 15
5.3 Coeficiente de curtosis o apuntamiento 15
6 Propiedades de la media y de la varianza 16
7 Ejercicio 17
8 Estadística bivariada 19
8.1 Covarianza cov(X,Y) 19
8.2 Coeficiente de Correlación 19
9 Tareas 21

Consideremos el siguiente conjunto de datos y sus poderaciones:

```
set.seed(15)
datos <- rexp(50)
pesos <- runif(50)
```

1 Primeros pasos

Calcular máximo, mínimo, tamaño y hacer un histograma:

```
min(datos)
```

```
[1] 0.008414212
```

```
max(datos)
```

```
[1] 4.55055
```

```
length(datos)
```

```
[1] 50
```

```
hist(datos,col = 'steelblue', main = 'Histograma',
xlab='datos',ylab='Frecuencia',freq = FALSE)
```

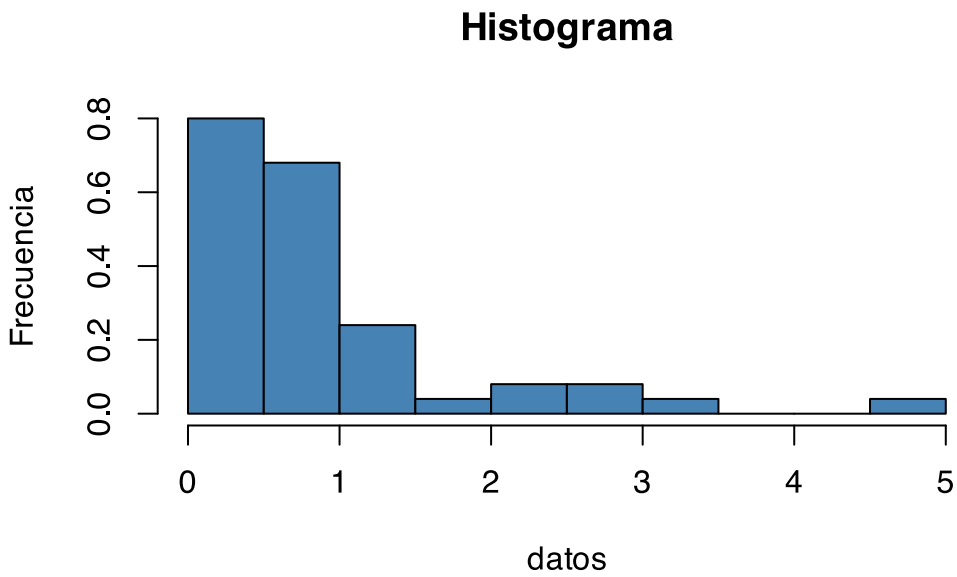

2 Medidas de tendencia central

Una medida de tendencia central o promedio para un conjunto de datos cuantitativos es un valor entre el dato mínimo y el dato máximo

2.1 Media aritmética ponderada

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$ y sean $w_1, w_2, ..., w_n$ las ponderaciones de los x_i, respectivamente, entonces la media aritmética de los x_i ponderada por los w_i está dad por:

$$M[X] = \overline{X} = \frac{\sum_{i=1}^{n} X_i w_i}{\sum_{i=1}^{n} w_i}$$

```
media_pon =weighted.mean(datos,pesos)
```

```
cat("Media ponderada =",media_pon)
```

```
Media ponderada = 0.8213001
```

```
media_pon1 = 1/sum(pesos)*sum(datos*pesos)
media_pon1
```

```
[1] 0.8213001
```

2.2 Media aritmética

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$, entonces la media aritmética de los x_i está dada por:

$$M[X] = \overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}$$

En la media aritmética ponderada cuando todas las ponderaciones son iguales.

```
mean(datos)
```

```
[1] 0.8656043
```

```
1/length(datos)*sum(datos)
```

```
[1] 0.8656043
```

2.3 Mediana

Es un valor que supera el 50% de los datos y es superado por el otro 50%.

$$Me[X] = \begin{cases} \text{Ordenar los datos} & \\ \text{Si n es par} & \dfrac{X_{\frac{n}{2}} + X_{\frac{n}{2}+1}}{2} \\ \text{Si n es impar} & X_{\frac{n+1}{2}} \end{cases}$$

```
median(datos)
```

```
[1] 0.5922824
```

2.4 Moda

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$, entonces la moda es el valor que más se repite en el conjunto de datos.

$$Mo(X) : \text{La moda es el dato que más se repite}$$

```
names(which.max(table(datos)))
```

```
[1] "0.00841421223061308"
```

2.5 Media geométrica

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$ positivos , entonces la media geométrica está dada por:

$$Mg(X) = \sqrt[n]{X_1 X_2 ... X_n} = (\Pi_{i=1}^{n} X_i)^{\frac{1}{n}} = 10^{M[\log(X)]} = e^{M[\ln(X)]}$$

Se utiliza para promediar tasas o índices.

```
mg=prod(datos)^(1/length(datos))
mg
```

```
[1] 0.5262525
```

```
exp(1)^mean(log(datos,exp(1)))
```

```
[1] 0.5262525
```

```
10^mean(log(datos,10))
```

```
[1] 0.5262525
```

2.6 Media armónica

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$ positivos diferentes de cero, entonces la media armónica está dada por:

$$Ma(X) = \frac{1}{\frac{1}{n}\sum_{i=1}^{n}\frac{1}{X_i}} = \frac{1}{M\left[\frac{1}{X}\right]}$$

```
ma = 1/(1/length(datos)*sum(1/datos))
ma
```

```
[1] 0.1754266
```

```
1/mean(1/datos)
```

```
[1] 0.1754266
```

2.7 Media general de orden h

Sea un conjunto de datos $\{X_1, X_2, ..., X_n\}$ positivos diferentes de cero, entonces la media general de orden $p \in \mathbb{R} - \{0\}$ está dada por:

$$M_p(X) = \left(\frac{1}{n}\sum_{i=1}^{n} X_i^p\right)^{\frac{1}{p}}$$

Casos especiales

$$M_1(X) = M(X)$$

$$M_{-1} = Ma(X)$$

$$M_{p\to 0} = Mg(X)$$

$$M_{p\to\infty} = X_{\text{máx}}$$

$$M_{p\to-\infty} = X_{\text{mín}}$$

```r
mh <- function(data,h){
  (mean(data^h))^(1/h)
}
mh(datos,2.5)
```

```
[1] 1.432136
```

2.8 Propiedad

$$X_{\text{mín}} \leq ... \leq Ma(X) = M_{-1}(x) \leq Mg(X) = M_0(X) \leq M(X) = M_1(X) \leq ... \leq X_{\text{máx}}$$

3 Percentiles

El percentil k-ésimo de X, $P_k(X)$, $0 \leq k \leq 100$, está dado por:

$$P_k(X) = \begin{cases} 1. \text{ Ordenar los datos} \\ 2. \text{ Calcular} \qquad i = \frac{kn}{100} \\ 3. \begin{cases} \text{Si i es entero} & \dfrac{X_i + X_{i+1}}{2} \\ \text{Si i no es entero} & X_{[i]+1} \end{cases} \end{cases}$$

$[i]$ es la parte entera de i. El percentil k de un conjunto de datos, P_k es un valor que supera el k% de los datos y es superado por el (100-k)% de los datos, $0 \leq k \leq 100$.

```
p37 =quantile(datos,.37) #percentil 37
p37
```

```
     37%
0.433868
```

```
quantile(datos)
```

```
          0%          25%          50%          75%         100%
0.008414212 0.311874954 0.592282371 1.007695793 4.550550211
```

```
quantile(datos,prob=c(.05,0.22,0.43,.95))
```

```
       5%       22%       43%       95%
0.1044510 0.2901630 0.5378021 2.6588917
```

3.1 Recorrido Intercuartílico

$$IQR(X) = P_{75}(X) - P_{25}(X) = Q_3(X) - Q_1(X)$$

```
IQR(datos)
```

```
[1] 0.6958208
```

3.2 Diagrama de Caja, box and whiskers, boxplot

```
boxp =boxplot(datos,horizontal = TRUE,col = 'steelblue',main="datos")
```

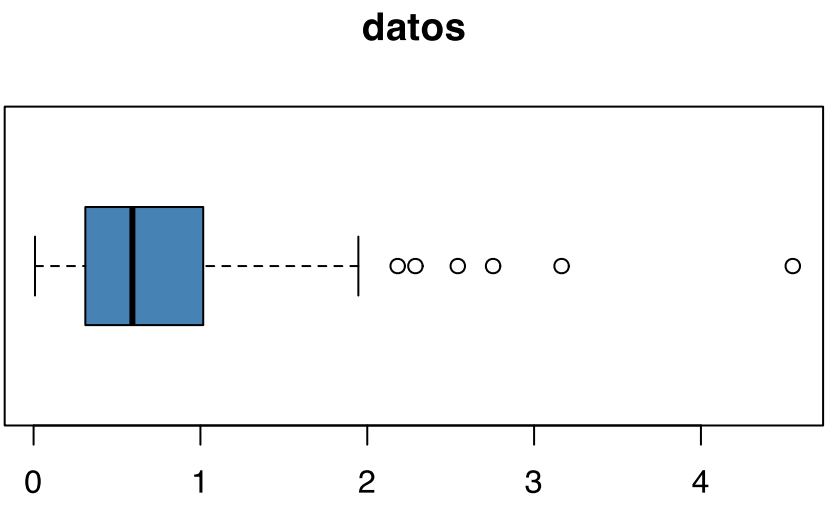


```r
str(boxp)
```

```
List of 6
 $ stats: num [1:5, 1] 0.00841 0.31014 0.59228 1.01682 1.94665
 $ n    : num 50
 $ conf : num [1:2, 1] 0.434 0.75
 $ out  : num [1:6] 2.75 3.16 2.18 2.29 4.55 ...
 $ group: num [1:6] 1 1 1 1 1 1
 $ names: chr ""
```

```r
boxp
```

```
$stats
            [,1]
[1,] 0.008414212
[2,] 0.310144352
[3,] 0.592282371
[4,] 1.016816903
[5,] 1.946645779

$n
[1] 50

$conf
```

```
          [,1]
[1,] 0.4343794
[2,] 0.7501853

$out
[1] 2.754151 3.164734 2.182293 2.288551 4.550550 2.542463

$group
[1] 1 1 1 1 1 1

$names
[1] ""
```

```
boxp[3] # outliers
```

```
$conf
          [,1]
[1,] 0.4343794
[2,] 0.7501853
```

3.3 Cuartiles

`nquantile(X,4)`

Hay tres cuartiles: Q_1, Q_2, Q_3:

$$Q_1(X) = P_{25}(X), \quad Q_2(X) = P_{50}(X), \quad Q_3(X) = P_{75}(X)$$

3.4 Deciles

`nquantile(X,10)`

Hay nueve deciles: $D_1, D_2, ..., D_9$:

$$D_1(X) = P_{10}(X), D_2(X) = P_{20}(X), ..., D_9(X) = P_{90}(X)$$

3.4.1 Propiedad

$$Q_2 = D_5 = P_{50} = Me(X)$$

3.5 Recorrido intercuartílico

El recorrido intercuartílico, $RIQ(X)$, es la diferencia entre el tercer y el primer cuartil, es el rango del 50% central de los datos:

$$RIQ(X) = Q_3(X) - Q_1(X) = P_{75}(X) - P_{25}(X)$$

3.6 Bigotes

$$B_1 = Q_1 - 1.5 \quad RIQ(X) = P_{25} - 1.5 \quad RIQ(X)$$

$$B_2 = Q_3 + 1.5 \quad RIQ(X) = P_{75} + 1.5 \quad RIQ(X)$$

Los datos menores al bigote 1 y/o mayores al bigote 2 se llaman datos **atípicos**, datos extremos o **outliers**. Un outlier es un dato muy grande o muy pequeño con respecto a los demás.

4 Medidas de dispersión

4.1 Rango

$$R(X) = X_{\max} - X_{\min}$$

```
rango=range(datos)
rango
```

```
[1] 0.008414212 4.550550211
```

```
rango[2]-rango[1]
```

```
[1] 4.542136
```

4.2 Recorrido intercuartílico

```
IQR(datos)
```

```
[1] 0.6958208
```

```
quantile(datos,.75)-quantile(datos,.25)
```

```
      75%
0.6958208
```

4.3 Varianza muestral

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^{n} \left(X_i - \overline{X}\right)^2$$

```r
var(datos)
```

```
[1] 0.8088705
```

```r
1/(length(datos)-1)*sum((datos-mean(datos))^2)
```

```
[1] 0.8088705
```

4.4 Desviación estándar muestral

$$\sigma_X = \sqrt{\sigma_X^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2}$$

```r
sd(datos)
```

```
[1] 0.8993723
```

```r
sqrt(var(datos))
```

```
[1] 0.8993723
```

```r
sqrt(1/(length(datos)-1)*sum((datos-mean(datos))^2))
```

```
[1] 0.8993723
```

4.5 Varianza poblacional

$$\sigma_X^2 = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

```r
(length(datos)-1)/length(datos)*var(datos)
```

```
[1] 0.7926931
```

4.6 Desviación estándar poblacional

$$\sigma_X = \sqrt{\sigma_X^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2}$$

```r
sqrt((length(datos)-1)/length(datos)*var(datos))
```

```
[1] 0.8903331
```

4.7 Suma de cuadrados

Otra medida de dispersión:

$$SC = \sum_{i=1}^{n} \left(X_i - \overline{X}\right)^2$$

Es, en realidad, n veces la varianza poblacional o $(n-1)$ veces la varianza muestral.

```r
SC = sum(datos-mean(datos))^2
SC
```

```
[1] 1.42488e-29
```

4.8 Desviación media

$$D_M(X) = \frac{1}{n} \sum_{i=1}^{n} |X_i - \overline{X}|$$

```r
1/length(datos)*sum(abs(datos-mean(datos)))
```

```
[1] 0.6195488
```

4.9 Coeficiente de variación muestral

El CV no tiene unidades y se expresa en porcentaje. Se utiliza para comparar la dispersión relativa de dos o más distribuciones.

$$CV(X) = \frac{S_X}{\overline{X}} = \frac{S_X}{M(X)}$$

```r
sd(datos)/mean(datos)*100
```

```
[1] 103.9011
```

4.10 Puntaje estandarizado o normalización

Es el número de desviaciones estándar que separan un dato de la media aritmética. Para estandarizar o normalizar un dato:

$$Z = \frac{x - M(X)}{s(X)}$$

```
scale(datos)[1:50]
```

```
 [1] -0.735375403  1.201995489 -0.679551180 -0.766720187 -0.225430902
 [6]  2.099850141 -0.637447400 -0.942238908 -0.502958806 -0.617608528
[11] -0.853640851 -0.287033025 -0.310119009  0.286639148  2.556371539
[16]  1.464008916  0.006119049 -0.101214012  1.582155253 -0.609911596
[21] -0.151196513  0.225329523  0.062793289 -0.197702550  4.097241948
[26] -0.591750726 -0.486299676 -0.365362331 -0.771290252 -0.678117588
[31] -0.348402674 -0.255728889 -0.087122930  0.127564655 -0.575658256
[36] -0.352742828  0.168131215 -0.221897638 -0.438162763  0.496786288
[41] -0.560148616 -0.761284300  0.651432203 -0.648257076 -0.373175253
[46] -0.837363757  0.330804100 -0.297687080 -0.953098229  1.864476976
```

```
z=(datos-mean(datos))/sd(datos)
z
```

```
 [1] -0.735375403  1.201995489 -0.679551180 -0.766720187 -0.225430902
 [6]  2.099850141 -0.637447400 -0.942238908 -0.502958806 -0.617608528
[11] -0.853640851 -0.287033025 -0.310119009  0.286639148  2.556371539
[16]  1.464008916  0.006119049 -0.101214012  1.582155253 -0.609911596
[21] -0.151196513  0.225329523  0.062793289 -0.197702550  4.097241948
[26] -0.591750726 -0.486299676 -0.365362331 -0.771290252 -0.678117588
[31] -0.348402674 -0.255728889 -0.087122930  0.127564655 -0.575658256
[36] -0.352742828  0.168131215 -0.221897638 -0.438162763  0.496786288
[41] -0.560148616 -0.761284300  0.651432203 -0.648257076 -0.373175253
[46] -0.837363757  0.330804100 -0.297687080 -0.953098229  1.864476976
```

5 Medidas de forma

5.1 Momentos

Momento de orden r con respecto al origen.

$$\mu'_r(X) = \frac{1}{n}\sum_{i=1}^{n} X_i^r$$

Momento de orden r con respecto a la media.

$$\mu_r(X) = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^r, \quad r = 0, 1, 2, \ldots$$

5.1.1 Casos especiales

$$\mu_0(X) = 1$$

$$\mu_1(X) = 0$$

$$\mu_2(X) = \sigma_X^2 = V(X)$$

$$\mu_3(X) = \frac{1}{n}\sum_{i=1}^{n}(X_i - -(X))^3$$

$$\mu_4(X) = \frac{1}{n}\sum_{i=1}^{n}(X_i - -(X))^4$$

$$\mu_r = \sum_{i=0}^{r}(-1)^i\binom{r}{i}\mu^i\mu'_{r-i}$$

```
library(moments)
all.moments(datos,central=TRUE,order.max = 4)
```

```
[1]  1.000000e+00 -7.549517e-17  7.926931e-01  1.499216e+00  4.905277e+00
```

```
all.moments(datos,absolute = TRUE,order.max = 4)
```

```
[1]  1.0000000  0.8656043  1.5419640  4.2062642 14.2212479
```

5.2 Coeficiente de sesgo o asimetría

$$\gamma_1(X) = \frac{\mu_3(X)}{\sigma_X^3}$$

5.3 Coeficiente de curtosis o apuntamiento

$$\gamma_2(X) = \frac{\mu_4(X)}{\sigma_X^4}$$

```
skewness(datos)
```

```
[1] 2.124255
```

```
kurtosis(datos)
```

```
[1] 7.806447
```

6 Propiedades de la media y de la varianza

Sean a y b constantes y X una variable, se cumple:

1. $M(a) = a$
2. $M(aX + b) = aM(X) + b$
3. $V(X) \geq 0$
4. $V(a) = 0$
5. $V(aX + b) = a^2 V(X)$

Para m grupos se sabe:

Grupo	**Número de elementos**	**Media**	**Varianza**
1	n_1	$\overline{X}_1$	V(X_1)
2	n_2	$\overline{X}_2$	V(X_2)
$\vdots$	$\vdots$	$\vdots$	$\vdots$
m	n_m	$\overline{X}_m$	V(X_m)

Entonces, la media y la varianza de todos los elementos como si fueran un solo grupo están dadas por:

$$M_T(X) = \frac{\sum_{i=1}^{m} n_i \overline{X}_i}{\sum_{i=1}^{m} n_i} \quad \text{media total}$$

$$V_T(X) = \frac{\sum_{i=1}^{m} n_i \left(\overline{X}_i - M_T(X)\right)^2}{\sum_{i=1}^{m} n_i} + \frac{\sum_{i=1}^{m} n_i V(i)}{\sum_{i=1}^{m} n_i} \quad \text{varianza total}$$

$$V_T(X) = V(M(X_i)) + M(V(i))$$

$$V_T(X) = \sigma_w^2 + \sigma_b^2$$

Varianza total = Intravarianza + Intervarianza

En el caso en que todas las $n_i = n$ son iguales y se tiene:

$$M_T(X) = \frac{1}{m} \sum_{i=1}^{m} \overline{X}_i$$

$$V_T(X) = \frac{\sum_{i=1}^{m} \left(\overline{X}_i - M_T(X)\right)^2}{m} + \frac{\sum_{i=1}^{m} V(i)}{m}$$

$$V_T(X) = V(M(X_i)) + M(V(i))$$

$$V_T(X) = \sigma_w^2 + \sigma_b^2$$

Varianza total = Intravarianza + Intervarianza

Si multiplicamos por m se obtienen las sumas de cuadrados:

$$mV(X) = mV(M()) + mM(V())$$

$$\sum_{i=1}^{n} \sum_{j=1}^{m} \left(X_{ij} - M_T\right)^2 = \sum_{i=1}^{m} \left(\overline{X}_i - M_T(X)\right)^2 + \sum_{i=1}^{m} V(i)$$

$$SCT = SCW + SCB$$

Llamadas respectivamente

SCT : suma de cuadrados total

SCW : suma de cuadrados dentro

SCB : suma de cuadrados entre

7 Ejercicio

Creemos un conjunto de datos con 60 datos, dividido en 6 grupos:

```
m = matrix(rexp(60),nrow = 10,ncol = 6)
m
```

```
            [,1]        [,2]       [,3]        [,4]        [,5]       [,6]
 [1,] 2.55564433 0.002539703 0.68123571 0.039133552 0.643151882 0.11041766
 [2,] 0.90777179 0.395059987 0.10155604 0.803595611 0.004750235 0.37271429
 [3,] 0.03198804 0.389062787 0.64353075 1.131725703 5.089803146 1.20657585
 [4,] 0.30940078 0.976180394 0.84485353 1.651561273 0.622285335 0.45934778
 [5,] 0.86516386 0.291702515 1.20531472 0.005125732 0.322643297 0.42750222
 [6,] 0.52347412 0.970509010 2.57907136 1.031521141 2.572251292 2.13115490
 [7,] 0.28116252 0.214706466 1.45822333 2.581334277 1.916168798 0.03742616
 [8,] 0.51589315 1.187536800 0.29520404 0.381965568 0.885250748 2.37181497
 [9,] 1.69059522 0.526189306 0.04482317 1.168739284 0.467094419 0.75982716
[10,] 0.40155583 0.461223999 1.33854347 1.096093945 0.003922596 0.33281354
```

Calculemos la varianza de todos los datos:

```
var(c(m))
```

```
[1] 0.8213962
```

convertido a `dataframe` queda:

```
m = as.data.frame(m)
m
```

```
           V1          V2         V3          V4          V5         V6
1  2.55564433 0.002539703 0.68123571 0.039133552 0.643151882 0.11041766
2  0.90777179 0.395059987 0.10155604 0.803595611 0.004750235 0.37271429
3  0.03198804 0.389062787 0.64353075 1.131725703 5.089803146 1.20657585
4  0.30940078 0.976180394 0.84485353 1.651561273 0.622285335 0.45934778
5  0.86516386 0.291702515 1.20531472 0.005125732 0.322643297 0.42750222
6  0.52347412 0.970509010 2.57907136 1.031521141 2.572251292 2.13115490
7  0.28116252 0.214706466 1.45822333 2.581334277 1.916168798 0.03742616
8  0.51589315 1.187536800 0.29520404 0.381965568 0.885250748 2.37181497
9  1.69059522 0.526189306 0.04482317 1.168739284 0.467094419 0.75982716
10 0.40155583 0.461223999 1.33854347 1.096093945 0.003922596 0.33281354
```

Media y varianza de los grupos (columnas de m):

```
ms = colMeans(m)
vars = sapply(m, var)
ms;vars
```

```
       V1        V2        V3        V4        V5        V6
0.8082650 0.5414711 0.9192356 0.9890796 1.2527322 0.8209595
```

```
       V1        V2        V3        V4        V5        V6
0.5895876 0.1445990 0.5848917 0.5903989 2.4897514 0.6797531
```

Media de las varianzas y varianza de las medias:

```
MV = mean(vars)
VM = var(ms)
```

```
MV + VM
```

```
[1] 0.9015278
```

8 Estadística bivariada

Ahora tenemos dos variables relacionadas X y Y.

```
X <- rnorm(25)
Y <- rexp(25)
```

8.1 Covarianza cov(X,Y)

La covarianza es una medida de asociación de dos variables.

$$cov(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{n-1} \text{ muestral}$$

$$cov(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{N} \text{ poblacional}$$

Si la covarianza es positiva decimos que las variables son directamente proporcionales, es decir que si una crece la otra también crece, i la covarianza es negativa decimos que las variables son inversamente proporcionales, es decir que si una crece la otra decrece. Si es cero decimos que las variables no están relacionadas.

```
var(X,Y)
```

```
[1] 0.6375702
```

Normalizando la covarianza se obtiene:

8.2 Coeficiente de Correlación

El coeficiente de correlación es una medida de asociación lineal de las dos variables.

```
plot(X,Y,main = "X vs Y")
```

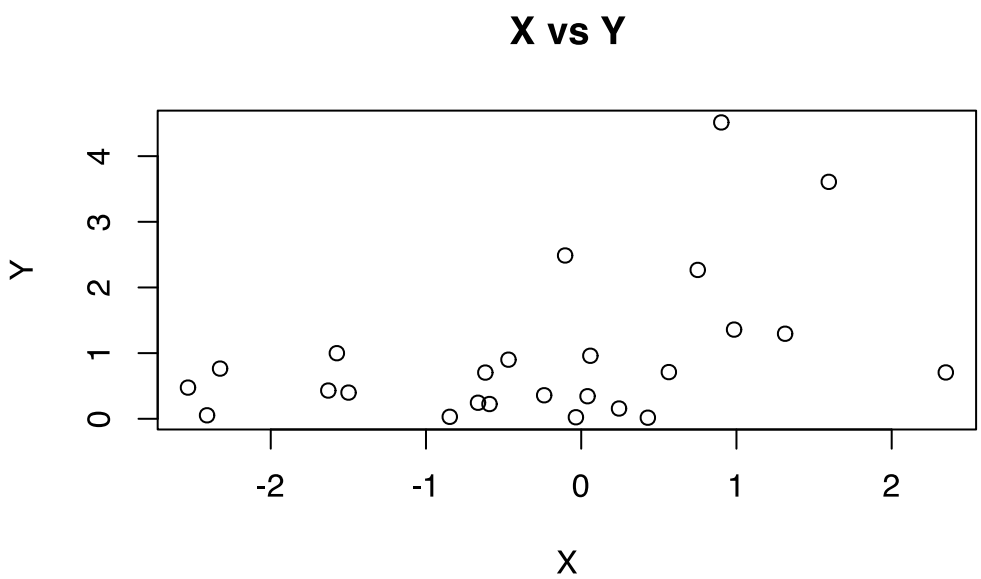

$$\rho = \frac{cov(x,y)}{\sigma_x \sigma_y}$$

$$r = \frac{cov(x,y)}{S(x)S(y)}$$

Siempre se tiene que

$$-1 \leq \rho \leq 1$$

$$-1 \leq \rho \leq 1$$

```
var(X,Y)
```

```
[1] 0.6375702
```

```
cor(X,Y)
```

```
[1] 0.4446693
```

Matriz de covarianzas:

```
df = data.frame(x=X, y=Y)
var(df)
```

```
          x         y
x 1.5960031 0.6375702
y 0.6375702 1.2880954
```

Matriz de correlaciones:

```r
cor(df)
```

```
          x         y
x 1.0000000 0.4446693
y 0.4446693 1.0000000
```

```r
pairs(df)
```

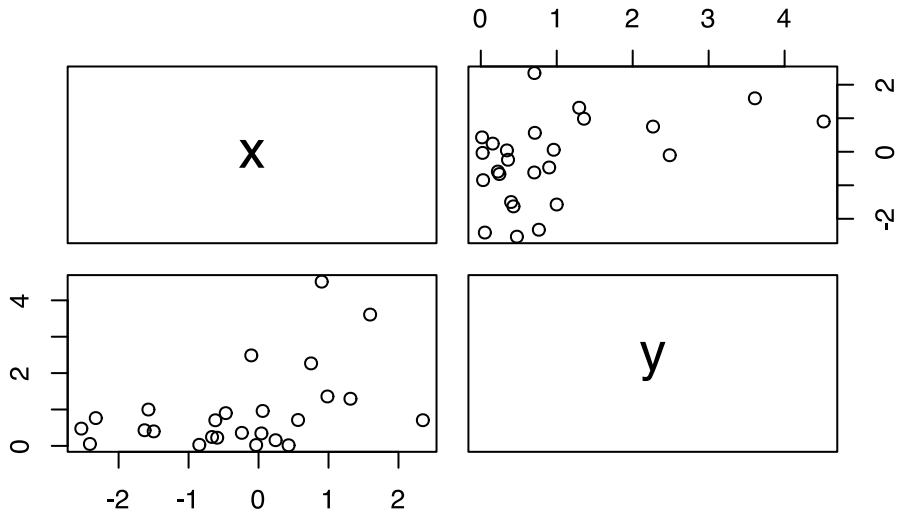

9 Tareas

Cree una función que

1. calcule los percentiles
2. estandarice un conjunto de datos
3. calcule los momentos
4. calcule la media general